

Regressão Logística

Baseado no material produzido por Andrew Ng e adaptado por Alcione de Paiva Oliveira DPI/UFV


Tipos de Aprendizado de Máquina



Regressão Logística

Regressão linear e logística



- Usa-se regressão linear quando se deseja prever um valor real a partir de uma função linear ajustada para valores de treinamento.



Regressão Logística

Regressão linear e logística

- No entanto, quando se deseja obter a probabilidade de classificação a regressão logística é a adequada.




Regressão Logística

Regressão linear e logística

- No entanto, quando se deseja obter a probabilidade de classificação a regressão logística é a adequada.


Dado o salário, deve-se aprovar um empréstimo (S/N)



Regressão Logística

Regressão linear e logística

- No entanto, quando se deseja obter a probabilidade de classificação a regressão logística é a adequada.




Regressão Logística

Regressão logística

- A regressão logística usa a função logística, de forma a manter infinitos scores entre 0 e 1.
- Uma função logística ou uma curva logística é um formato de “S” comum (curva sigmóide), com equação :

$$f(x) = \frac{1}{1 + e^{-\lambda x}}$$



Regressão Logística

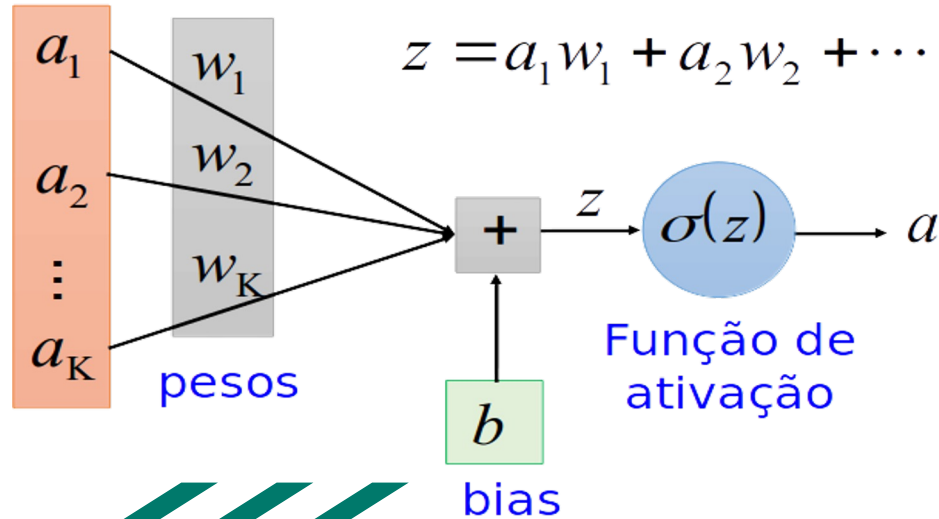
Regressão logística

- Então, suponha um vetor de entradas $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ e um vetor de pesos $\mathbf{w} = \{w_1, w_2, \dots, w_n\}$ e uma constante b (também denominado de **bias**), a função linear z é definida como $z = \mathbf{w}^T \mathbf{x} + b$.
- Ao aplicarmos a função logística (**função de ativação**) σ à z obtemos um valor entre 0 e 1:


$$\sigma(z) = \sigma(z = \mathbf{w}^T \mathbf{x} + b)$$

Regressão Logística

Regressão logística



É um neurônio artificial




Regressão Logística

Regressão logística: Exemplo

- Vetor com valor de salário e valor pedido de empréstimo (em unidade de milhar) $\mathbf{x} = \{1, 2\}$ e um vetor de pesos $\mathbf{w} = \{0.5, 0.1\}$ e uma constante $b=0.1$, então z , definida como $z = \mathbf{w}^T \mathbf{x} + b$ é

$$1 \times 0.5 + 2 \times 0.1 + 0.1 = 0.8$$



- Ao aplicarmos a função logística (**função de ativação**) σ à z obtemos um valor entre 0 e 1:

$$\sigma(z) = \sigma(z = \mathbf{w}^T \mathbf{x} + b) = 1/(1 + e^{-0.8}) = 0.69$$

Regressão Logística

Regressão logística

- Mas como saber se o valor emitido está correto?
- O valor de 0.69 (69%) para emprestar para uma pessoa que ganha mil Reais e pediu dois mil empréstimos está correto?
- Como é feito o ajuste (aprendizado) da regressão logística?

Regressão Logística

Regressão logística

- O aprendizado é feito por meio do ajuste dos pesos.
- O ajuste é feito por meio da correção em etapas, dos pesos, a partir erro apresentado na saída de exemplos, cuja saída é conhecida (**aprendizado supervisionado**)

Regressão Logística

Função de perda (loss function)

$$\hat{y} = \sigma(z = \mathbf{w}^T \mathbf{x} + b) \text{ onde } \sigma(z) = 1/(1+e^{-z})$$

Dado um conjunto $C = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$ queremos que $\hat{y}^{(i)} \approx y^{(i)}$.

A loss function $L(\hat{y}, y)$ indica o quanto se errou.

Existem várias funções de perda:

Por que elevar ao quadrado?

$$L(\hat{y}, y) = 1/n \sum_{i \in C} (\hat{y}^{(i)} - y^{(i)})^2 \text{ (Erro Médio Quadrático - MSE)}$$

*Mas não é uma boa If

Regressão Logística

Função de perda (loss function)

$$\hat{y} = \sigma(z = \mathbf{w}^T \mathbf{x} + b) \text{ onde } \sigma(z) = 1/(1+e^{-z})$$

Dado um conjunto $C = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$ queremos que $\hat{y}^{(i)} \approx y^{(i)}$.

A loss function $L(\hat{y}, y)$ indica o quanto se errou.

Existem várias funções de perda:

$$L(\hat{y}, y) = -(y \log \hat{y} + (1-y) \log(1-\hat{y})) \text{ (Logistic loss)}$$

Regressão Logística

Função de perda (loss function)


$$\hat{y} = \sigma(z = \mathbf{w}^T \mathbf{x} + b) \text{ onde } \sigma(z) = 1/(1+e^{-z})$$

Dado um conjunto $C = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$ queremos que $\hat{y}^{(i)} \approx y^{(i)}$.

A loss function $L(\hat{y}, y)$ indica o quanto se errou.

Existem várias funções de perda:

$$L(\hat{y}, y) = -(y \log \hat{y} + (1-y) \log(1-\hat{y})) \text{ (Logistic loss)}$$



Se $y = 1$ então $\mathcal{L} = -\log \hat{y}$ e para minimizar a perda \hat{y} precisa ser grande
Se $y = 0$ então $\mathcal{L} = -\log(1-\hat{y})$ e para minimizar a perda \hat{y} precisa ser pequeno

Regressão Logística

Função de perda (loss function)

$$\hat{y} = \sigma(z = \mathbf{w}^T \mathbf{x} + b) \text{ onde } \sigma(z) = 1/(1+e^{-z})$$

Dado um conjunto $C = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$ queremos que $\hat{y}^{(i)} \approx y^{(i)}$.

A loss function $L(\hat{y}, y)$ indica o quanto se errou.

Existem várias funções de perda:

$$J(\mathbf{w}, b) = 1/m \sum_{i \in C} \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) = -1/m \sum_{i \in C} [y^{(i)} \log \hat{y}^{(i)} + (1-y^{(i)}) \log(1-\hat{y}^{(i)})]$$

Regressão Logística

Regressão logística (**Gradiente descendente**)

- **Uma vez detectado o erro como ajustar a função para minimizar o erro?**

Ajustando os pesos w

- Podemos ajustar os pesos alterando no sentido inverso da inclinação do hiperplano do erro. (**Gradient Descent**)
- Obtemos a inclinação derivando (ou obtendo a *derivada direcional* no caso de vetor) a função de perda.

Regressão Logística


Regressão logística (**Gradiente descendente**)

$$f'(x) = 2x \sin(x) + x^2 \cos(x)$$

No ponto (2.8, 2.6) $f'(x) = -5.511$

Então ajustamos no sentido inverso:

$$x = 2.8 - (0.005 \times -5.511) = 2.82$$



Regressão Logística

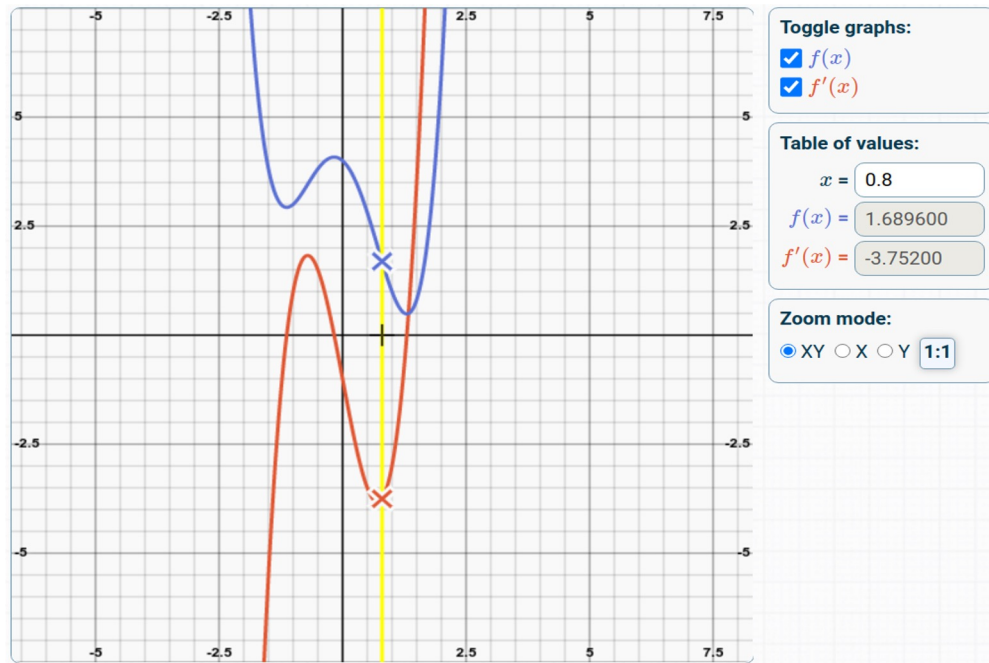
Regressão logística (Gradiente descendente) **Outro Exemplo**

$$f(x) = x^4 - 3x^2 - x + 4$$

$$f'(x) = 4x^3 - 6x - 1$$

Se ajustarmos ajustamos com alpha muito grande, iremos passar o ponto mínimo:

$$x = 0.8 - (0.3 \times -3.75) = 1.9$$



Regressão Logística

Regressão logística (**Gradiente descendente**)

- No caso de vetor e no âmbito do cálculo vetorial a inclinação é dada pelo gradiente da superfície de erro.
- O Gradiente de uma função $f(\mathbf{x}): \mathbb{R}^n \rightarrow \mathbb{R}$ é um vetor da seguinte forma:

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}(\mathbf{x}), \frac{\partial f}{\partial x_2}(\mathbf{x}), \dots, \frac{\partial f}{\partial x_n}(\mathbf{x}) \right)$$

Regressão Logística

Regressão logística (**Gradiente descendente**)

- O que desejamos é onde no ponto a o gradiente é o mais inclinado.
- Ou seja dado um vetor unitário u que parte do ponto qual é a inclinação de u . (derivativa direcional)

$$D_u f(\mathbf{a}) = \lim_{h \rightarrow 0} (f(\mathbf{a} + hu) - f(\mathbf{a})) / h$$

Regressão Logística


Regressão logística (**Gradiente descendente**)

- $D_{\mathbf{u}}f(\mathbf{a})$ é máximo (m maior inclinação) é dada pela fórmula:

$$D_{\mathbf{m}}f(\mathbf{a}) = \nabla f(\mathbf{a}) / \|\nabla f(\mathbf{a})\|$$

Regressão Logística

Regressão logística (Gradiente descendente)



$\theta = 0$


$u = (-0.91, -0.42)$

$a = (6.7, 1.1)$

$\nabla f(a) = (-1.81, -0.85)$

$D_u f(a) = 2.00$

$\|\nabla f(a)\| = 2.00$



$\theta = 0$

$u = (-0.91, -0.42)$

$D_u f(a) = 2.00$

$\nabla f(a) = (-1.81, -0.85)$

$\|\nabla f(a)\| = 2.00$

$f(a) = 4.87$

https://mathinsight.org/applet/gradient_directional_derivative_mountain


Regressão Logística

Regressão logística (Gradiente descendente)

$$z = w^T x + b$$


$$\hat{y} = a = \sigma(z)$$

$$\mathcal{L}(a, y) = -(y \log(a) + (1 - y) \log(1 - a))$$



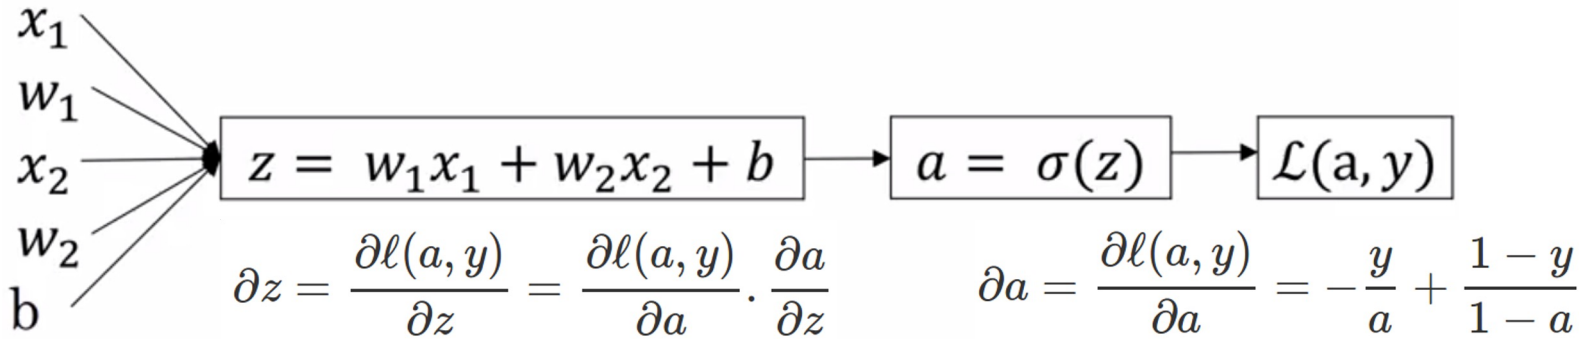
Regressão Logística

Regressão logística (Gradiente descendente)



Regressão Logística

Regressão logística (Gradiente descendente)



Onde: $\frac{\partial a}{\partial z} = a(1 - a)$

Logo: $\partial z = a - y$

Regressão Logística

Regressão logística (Gradiente descendente)

Regra da cadeia

Seja $F = f \circ g$, ou de forma equivalente, $F(x) = f(g(x))$, então

$$F'(x) = f'(g(x))g'(x).$$

ou

$$\frac{dz}{dx} = \frac{dz}{dy} \cdot \frac{dy}{dx}.$$

Regressão Logística

Regressão logística (Gradiente descendente)

Regra da cadeia

Exemplo: $y = e^{\sin x^2}$.

$$y = f(u) = e^u,$$

$$u = g(v) = \sin v,$$

$$v = h(x) = x^2.$$

$$\frac{dy}{du} = f'(u) = e^u,$$

$$\frac{du}{dv} = g'(v) = \cos v,$$


$$\frac{dv}{dx} = h'(x) = 2x.$$

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dv} \cdot \frac{dv}{dx}.$$

$$\frac{dy}{dx} = e^{\sin x^2} \cdot \cos x^2 \cdot 2x.$$

Regressão Logística

Regressão logística (Gradiente descendente)




Onde: $\frac{\partial a}{\partial z} = a(1 - a)$

Logo: $\partial z = a - y$

$$\frac{\partial z}{\partial w_1} = dw_1 = x_1 dz \quad dw_2 = x_2 dz \quad db = dz$$

Regressão Logística

Regressão logística (Gradiente descendente)



Onde: $\frac{\partial a}{\partial z} = a(1-a)$ Logo: $\partial z = a - y$

$w_1 := w_1 - \alpha \frac{\partial \mathcal{L}}{\partial w_1}$
 $w_2 := w_2 - \alpha \frac{\partial \mathcal{L}}{\partial w_2}$
 $b := b - \alpha \frac{\partial \mathcal{L}}{\partial b}$

$$\frac{\partial z}{\partial w_1} = dw_1 = x_1 dz \quad dw_2 = x_2 dz \quad db = dz$$

Regressão Logística

FIM